

论文《ID-Agnostic User Behavior Pre-training for Sequential Recommendation》的复现报告

摘要

经典的序列推荐算法基于物品 ID 编码物品，通过建模不同的神经网络架构建模用户行为，以捕捉潜在的用户兴趣。本报告复现的 IDA-SR 模型提出了一种与物品 ID 无关的用户行为预训练序列推荐方法。具体地，该方法抛弃了基于 ID 编码的物品表示，采用预训练语言模型作为文本编码器从丰富的文本信息中学习物品表示，设计一个端到端的预训练网络建模用户偏好，并在下游任务上微调以提高推荐性能。本报告根据其论文细节复现模型，其复现结果在三个公开数据集接近原始论文报告的结果。本复现报告证明，IDA-SR 模型在下游数据集微调时能够接近基于物品 ID 编码的模型，但性能依然严重依赖基于物品 ID 表示的微调；同时通过消融实验证明，该模型提出的置换物品预测预训练任务表现不稳定。报告研究发现，影响模型性能的瓶颈是底层的文本编码表示和语义空间适配层，因此提出了一种基于局部敏感哈希的语义映射网络。该网络可以弥补预训练模型空间和推荐空间的语义差距，有效地提高基于文本的语义表示迁移至推荐场景的能力。

关键词：序列推荐；预训练网络；物品表示；局部敏感哈希；语义映射

1 引言

在过去十年，序列推荐是学术界和工业界的一个研究热点。经典的建模方法通过唯一的 ID 编码物品，并采用不同的神经网络架构建模用户行为偏好，例如基于循环神经网络 [1] 和基于 Transformer 的方法 [2]。这种建模范式被称为基于 ID 的物品表示推荐方法。这种建模范式存在 3 个不足：1. 高度依赖用户-物品的交互数据来学习物品表示，当交互数据稀疏时很难学习到高质量的物品表示；2. 基于 ID 的物品表示可以学习 ID 之间的关联，但是无法有效表达物品的特征语义；3. 基于 ID 的物品表示无法迁移至新的场景。

自然语言处理领域的进步为推荐范式的变革带来了新的研究思路。文本信息广泛存在于推荐系统平台，物品的文本描述信息是对物品特征和属性的表达，且不同于基于 ID 的物品表示，文本表示天然具备良好的跨平台能力。

因此，本报告复现的 IDA-SR 模型 [3] 抛弃了传统的基于物品 ID 编码的推荐范式，采用物品的描述文本建模物品表示。与传统采用物品文本增强基于物品 ID 表示的方法 [4] 不同，IDA-SR 模型旨在探索完全基于文本表示的序列推荐方法。该论文发表于第二十八届全国信息检索学术会议 (CCIR2022)，并入选为最佳论文候选。该研究领域属于基于文本表示的推荐范式的经典工作。该论文提供了一个结合自然语言预训练模型和序列推荐算法结合的切入点，可以为后续的相关研究提供思路。

2 相关工作

2.1 基于 ID 建模的序列推荐

推荐系统是一种应用于信息平台的自动化程序，能够减少信息过载的问题。用户的行为序列是能够反映用户偏好的重要信息，因此，序列推荐近年来成为工业界和学术界的研究热点。[1]。

GRU4Rec 模型最早将门控神经网络应用于建模用户行为序列 [1]。后续的相关工作将不同的神经网络架构应用于用户序列建模，例如基于 Transformer 架构的方法 [2, 5, 6]，基于多层感知机的方法 [7]，基于图神经网络的方法 [8, 9]。部分工作除了挖掘用户物品交互行为序列的顺序依赖，还引入了丰富的额外信息（例如物品特征）[4, 10] 以及自监督信号增强物品表示 [10-12]。

然而，以上的相关研究都是基于物品 ID 表示的建模范式，通过唯一的 ID 编码物品，并学习物品之间的共现关系。这种建模范式存在 3 个不足：1. 高度依赖用户-物品的交互数据来学习物品表示，当交互数据稀疏时很难学习到高质量的物品表示；2. 基于 ID 的物品表示可以学习 ID 之间的关联，但是无法有效表达物品的特征语义；3. 基于 ID 的物品表示无法迁移至新的场景。不同场景的物品 ID 之间无法一一对应。针对每个特定的数据域或平台，需要重新训练一个序列推荐模型，造成资源的浪费。

2.2 基于文本模态的序列推荐

文本信息广泛存在于各类互联网平台，能够有效表示物品特征。近年来，随着自然语言处理领域的进步，相关研究表明，自然语言文本能够在跨平台或者跨任务中承担通用的语义表示的作用 [13]。

基于文本模态的序列推荐算法的核心思想是，采用物品的相关描述文本信息（例如物品描述、物品标题、物品品牌等等，称为物品文本）作为通用的物品表示。基于模态的建模通常分为两个步骤，首先采用预训练的语言模型编码固定住的语义表示，其次将提取出的语义表示作为通用可迁移的物品表示加入到推荐系统中。但是这类方法存在一个重要的挑战：文本的语义空间无法直接适用于推荐任务。直接采用原始的语义表示作为附加特征可能会降低推荐系统的性能。

为了解决语义表示和推荐领域的对齐问题，IDA-SR 模型采用了一个简单的语义转换多层感知机，将预训练的语义表示转换成通用的推荐语义表示 [3]。论文 [14] 在此基础上，引入了参数白化的方法，将多个领域的文本进行对齐，并转化为通用的语义表示。VQ-Rec 引入了一种矢量量化方法，将文本表示转换为中间层的 code 表示，并通过聚合多重中间 code 表示作为语义表示 [15]。不同于上述方法，MoRec 模型认为预训练提取的语义表示无法有效适用于推荐空间，它提出了一种端到端的训练方式，通过共同训练预训练语言模型和下游推荐模型，有效提高语义表达的能力，但是需要消耗庞大的计算资源 [16]。

本文引入一种基于局部敏感哈希的语义映射组件网络，该网络采用可学习的局部敏感哈希算法实现，将预训练的语义表示转换成多重局部哈希编码，并映射到多重可学习的哈希表示中，通过聚合哈希表示得到更新的语义表示。该方法能够增强语义表示适用于推荐领域的能力。实验证明，该组件网络计算资源小，而且性能有效。

3 本文方法

3.1 本文方法概述

本文复现的方法模型框架如图 1 所示，该模型图源自论文 [3]：

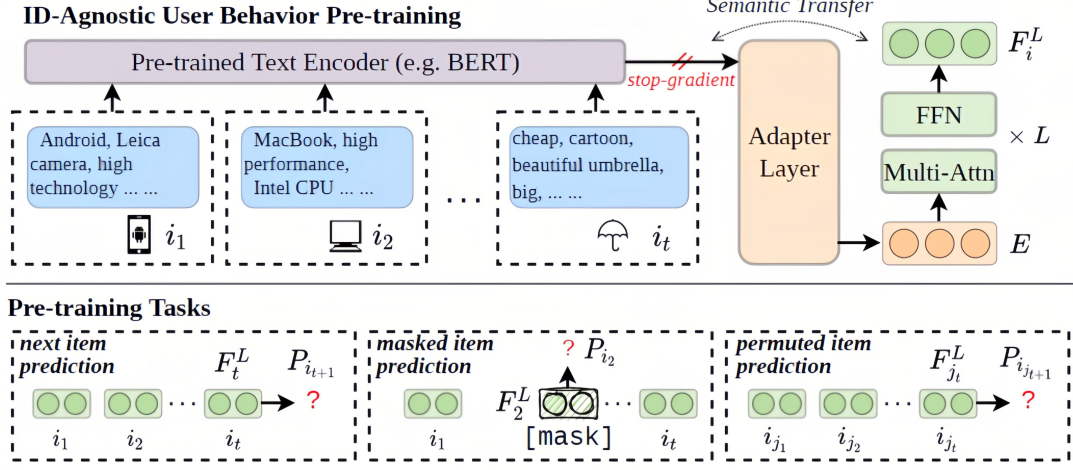


图 1. 方法示意图

IDA-SR 模型包括两个步骤：与 ID 无关的用户行为预训练阶段和微调阶段。其中模型框架包括以下组件：预训练文本编码层、语义转换层、序列偏好编码层。

在预训练阶段，IDA-SR 模型引入了三个预训练任务，分别是下一个物品预测任务、掩码物品预测任务以及置换物品预测任务。在微调阶段，IDA-SR 模型引入两种微调模式，分别是与 ID 无关的微调和与 ID 有关的微调。

在下列章节中，将详细介绍相关内容。

3.2 预训练文本编码层

在 IDA-SR 模型中，采用一个预训练语言模型作为文本编码层，直接编码物品的相关描述文本的语义向量作为物品表示。

具体地，本文采用了一个预训练的 BERT 模型作为文本编码器。给定一个物品 i 的对应物品文本 $C_i = \{w_1, w_2, \dots, w_m\}$ ，其中 w_i 表示第 i 个单词，增加一个额外的 token 到 C_i 中作为词序列的输入，即 $\bar{C}_i = \{[CLS], w_1, w_2, \dots, w_m\}$ 。将词序列输入到 BERT 模型中，将 $[CLS]$ 这个 token 的表示作为与 ID 无关的物品表示。因此，可以得到物品文本表示矩阵 $M_T \in R^{|I| \times \tilde{d}}$ ，其中 \tilde{d} 表示物品文本表示矩阵的潜在维度。

3.3 语义转换层

预训练语言模型提取的文本语义表示不能直接适用于推荐空间，因此，IDA-SR 模型提出一种简单的语义转换层，将原始的文本表示转换成适用于推荐任务的语义表示，其公式如下：

$$\tilde{m}_i = \sigma(\sigma(m_i W_1 + b_1) W_2 + b_2) \quad (1)$$

其中， $m_i \in M_T$ 是输入的物品表示， $\tilde{m}_i \in R^{1 \times d}$ 是更新之后的物品表示。

3.4 序列偏好编码层

给定一个 n 长度的物品序列, 在物品嵌入矩阵 M_T 中查表, 得到输入矩阵 $E_T \in R^{n \times d}$ 。为了能够学习到物品在序列中的位置信息, 构造一个可学习的位置嵌入矩阵 $P \in R^{n \times d}$ 。因此最早得到的输入矩阵 $E \in R^{n \times d}$ 是两个矩阵的和, 即: $E = E_T + P$ 。

为了建模物品序列中的序列偏好, 采用一个经典的自注意力框架建模, 其架构包括两个子层: 多头自注意力层 ($MultiHeadAttn$) 和前馈神经网络层 (FFN), 其公式如下:

$$F^{l+1} = FFN(MultiHeadAttn(F^l)) \quad (2)$$

其中 F^l 是第 l 层的输出, 当 $l = 0$ 时, 设置 $F^l = E$ 。

为了能够有效训练网络, 在这里引入三种预训练任务:

下一物品预测任务: 该任务是经典的序列推荐训练任务, 给定一个物品的交互行为序列, 预测用户下一时刻的物品。在这个预训练任务中, 计算用户对候选物品集的偏好如下:

$$P_{pre}(i_{t+1}|S) = softmax(F_t^L \widetilde{M}_T^T)_{i_{t+1}} \quad (3)$$

其中, $S = i_{1:t}$ 是用户行为交互序列, F_t^L 是第 L 层序列偏好编码层的在第 t 时刻的输出。

掩码物品预测任务: 该预训练任务最早出现在 BERT4Rec [6]。在该任务中, 随机地掩盖掉序列中的一些物品 (采用 [MASK]token 将其掩盖), 然后基于序列的上下文信息预测这些被掩盖的物品。在这个预训练任务中, 计算用户对候选物品集的偏好如下:

$$P_{pre}(i_{t+1}|S) = softmax(F_t^L \widetilde{M}_T^T)_{i_t} \quad (4)$$

其中, S 是经过掩码操作后的交互行为历史序列, F_t^L 是第 L 层序列偏好编码层的在第 t 时刻的输出。

置换物品预测任务: 该任务旨在对原始序列中的物品位置进行置换, 假设给定物品序列为 $i_{1:t} = i_1, i_2, \dots, i_t$, 生成置换序列 $i_{j_1:j_t} = i_{j_1}, \dots, i_{j_t}$ 。将置换物品序列进行输入, 计算用户对候选物品集的偏好如下:

$$P_{pre}(i_{t+1}|S) = softmax(F_{j_t}^L \widetilde{M}_T^T)_{i_{j_{t+1}}} \quad (5)$$

其中, $S = i_{j_1:j_t}$ 是置换后的用户行为交互序列, F_t^L 是第 L 层序列偏好编码层的在第 t 时刻的输出。

结合这三个预训练任务, 采用交叉熵损失函数来训练网络, 其公式如下:

$$L_{pre} = - \sum_{u \in U} \sum_{t \in T} \log P_{pre}(i_t = i_t^* | S) \quad (6)$$

其中, i_t^* 是真例子 ground truth 物品, T 是预测的位置物品。

3.5 适用于推荐任务的微调

经过预训练模型以后, 将在下游任务上微调模型。在 IDA-SR 中引入两种微调模型的方法。

与 ID 无关的微调: 没有考虑任何新引入的模块参数, 直接微调预训练模型中的物品表示, 计算第 i 个物品在第 t 步中基于上下文的用户偏好分数如下:

$$P_{fine}(i_{t+1}|i_{1:t}) = \text{softmax}(F_t^L \widetilde{M}_T^T)_{i_{t+1}} \quad (7)$$

其中, \widetilde{M}_T 是更新后的物品表示矩阵, F_t^L 是第 L 层序列偏好编码层的在第 t 时刻的输出。

与 ID 有关的微调: 引入一个可学习的物品 ID 嵌入矩阵 $M_I \in R^{|I| \times d}$, 结合 M_I 和基于文本的物品表示矩阵 \widetilde{M}_T 作为最终的物品表示, 计算第 i 个物品在第 t 步中基于上下文的用户偏好分数如下:

$$P_{fine}(i_{t+1}|i_{1:t}) = \text{softmax}(F_t^L (\widetilde{M}_T + M_I)^T)_{i_{t+1}} \quad (8)$$

只考虑在该微调阶段引入物品 ID, 而模型的其他部分则在预训练阶段完成预训练。在微调阶段, 依然使用交叉熵损失训练模型。

4 复现细节

4.1 与已有开源代码对比

本报告实现的 IDA-SR 模型没有公布任何源代码, 本报告完全基于论文报告细节进行实现。本文采用的代码框架基于论文的发表单位-中国人民大学人工智能学院自研的伯乐推荐算法框架 [17]。但是复现的论文结果性能没有完全达到原论文报告的结果。

因此, 本报告基于复现代码进一步改进模型。具体地, 本报告首先分析了模型提出的三种预训练任务, 并通过消融实验证明, 引入置换物品预测任务对于模型性能提高无效。其次, 报告通过分析模型参数占比, 分析影响模型性能瓶颈的因素, 发现预训练的语义表示无法有效适用于推荐领域, 其语义转换层性能不稳定。最后, 本报告引入一种基于局部敏感哈希的语义映射组件, 模型增强语义转换的能力。

本报告的复现围绕以下研究问题进行:

研究问题 1: IDA-SR 模型在两种微调方式下能否达到其论文报告的结果?

研究问题 2: IDA-SR 提出的三种预训练任务是否有效?

研究问题 3: 在 IDA-SR 中, 影响模型性能瓶颈的因素是什么?

研究问题 4: 本报告提出的基于局部敏感哈希的语义映射网络是否有效?

研究问题 5: 影响语义映射网络的关键参数是什么?

4.2 数据集和评估方式

在本报告中, 采用原论文使用的三个亚马逊评论数据集 [18], 该数据集包含产品评分、丰富的文本信息 (例如, 标题、品牌、描述)。本报告采用 2018 年公布的版本, 5-core 的数据集, 其名称分别为: Food、Instrument 和 Arts。每个数据集的每个用户或者每个物品至少出现 5 次。其数据集的统计特征如表 1 所示。

为评估模型性能, 本报告采用了与论文一致的评估指标, 即 top-k 的 Hit Ration(HR@k) 和 Normalized Discounted Cumulative Gain(NDCG@k)。其中 $k=10$ 。采用留一法作为评估策略, 对于每个用户, 采用这个用户从未交互过的物品作为负样本。

表 1. 数据集统计特征

数据集	Food	Instruments	Arts
用户数	115,349	24962	45486
物品数	39,670	9964	21019
交互数	1,027,413	208926	395150

4.3 模型实现的参数细节

IDA-SR 论文中并没有披露实现模型实现的参数细节。因此，本报告实现的模型代码基于中国人民大学公布的 recbole 推荐平台实现 [17]，并通过超参数搜索得到最好的参数设置。

本报告探究的最好的参数设置如下：学习率设置为 0.001，物品表示向量的维度为 256，神经网络的隐藏层维度为 512，dropout 的比例设置为 0.5。注意力层数为 2，多头注意力的头数量为 2。训练和评估的批处理大小为 2048。

在语义转换层中，中间层 MLP 可学习的向量维度为 512。在三个预训练任务中，掩码物品预测任务中，掩码比例为 0.1；在置换物品预测任务中，随机置换的比例为 0.1；三个预训练任务的损失权重是不一样的，掩码物品预测任务和置换物品预测任务的损失权重都是 0.1，而下一物品预测任务的损失权重为 1。

本文采用的 BERT 预训练语言模型为：BERT-base-cased，其输出的向量维度为 768。在本文提出的局部哈希的语义映射组件网络中，超平面的维度为 10，哈希层数为 3，哈希编码表示层为 3，中间神经网络隐藏层为 4。

4.4 创新点-基于局部敏感哈希的语义映射组件

在 IDA-SR 模型中，采用简单的语义转换层将预训练的文本语义表示映射匹配至推荐空间。但是其语义转换层实现较为简单，仅仅采用两层的 MLP 层实现，并且通过后续的实验 5.3 分析可知，其语义转换层的设计影响了模型性能。因此，本文主要引入一种基于局部敏感哈希 (Locality Sensitive Hashing, LSH) 的语义映射组件网络替换 IDA-SR 中的语义转换层，并通过实验证明其有效性。其网络组件架构如图 2 所示

首先，给定一个物品文本的预训练表示向量 $m_i \in R^{1 \times d}$ 作为输入，采用 h 个随机超平面 w_1, \dots, w_h 将其映射到一组二元向量 $(1_{w_1^T m_i > 0}, \dots, 1_{w_h^T m_i > 0})$ ，该二元向量中的每个元素取值为 $x \in 0, 1$ 。其公式如下：

$$(1_{w_1^T m_i > 0}, \dots, 1_{w_h^T m_i > 0}) = \text{hashmap}(w_1, \dots, w_h) * m_i \quad (9)$$

随后，根据这组二元向量将其映射成一个哈希编码，其公式如下：

$$c_k = \sum_{i=1}^h 2^{i-1} 1_{w_i^T m_i > 0} \quad (10)$$

重复 m 次以上过程，得到对应的哈希向量索引 c_0, c_1, \dots, c_{m-1} 。同时，构造 m 个独立可学习的哈希表示编码层 $E_{hash}^i \in R^{|I| \times d}$ 。采用第 i 哈希向量索引去第 i 个哈希表示编码层中查表，得到 m 个哈希编码表示向量，每个哈希编码表示向量和物品 ID 的表示向量 $e_i \in M_I$ 进行点

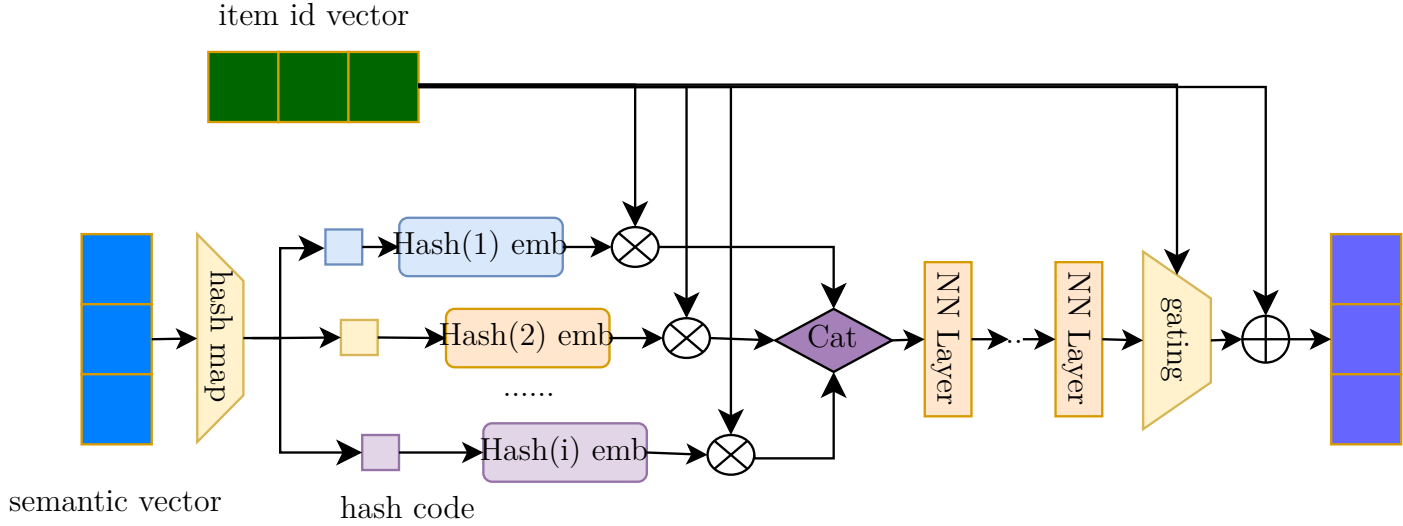


图 2. 基于局部敏感哈希的语义映射组件

乘以更新哈希编码表示。这个操作使得哈希表示能够有效融合物品 ID 和文本语义信息，在梯度更新的时候使得多个哈希嵌入表能够学习、转换物品 ID 语义和物品文本语义信息，其公式如下：

$$e_{hash}^m = e_{hash}^m * e_i \quad (11)$$

其中， $e_{hash}^i \in R^{1 \times d}$ 是哈希向量索引中 c_i 在第 i 个哈希表示编码层 E_{hash}^i 中的表示向量。

为了提高模型的泛化能力，将全部的哈希编码表示拼接送入一个多层的隐藏神经网络层中，通过多层神经网络学习中间表示。其公式如下：

$$\tilde{m}_i = MultiDNN(Cat[e_{hash}^1; e_{hash}^2, \dots, e_{hash}^m]) \quad (12)$$

其中 $MultiDNN$ 表示多层的神经网络层， Cat 表示拼接操作。

在输出时，采用一个残差门控机制进一步融合物品 ID 表示向量和神经网络中间表示，作为最终更新的文本表示向量。

$$Resnet - Gating(\tilde{m}_i, e_i) = g * \tilde{m}_i + (1 - g) * e_i \quad (13)$$

$$\tilde{m}_i = Resnet - Gating(\tilde{m}_i, e_i) + e_i \quad (14)$$

其中 \tilde{m}_i 是更新之后的物品表示， g 是可学习的中间门控向量。为了区分以上的模型，将这个改进的模型命名为 LSH-SR 模型。

5 实验结果分析

5.1 模型性能比较

首先，本报告中复现的模型性能和原始论文报告中的模型结果进行对比，同时也报告基于局部敏感哈希的语义映射改进方法的性能。因此，本节主要回答问题 1，下面将详细对实验

表 2. 模型性能比较

data	Metric	IDA-SR _t (o)	IDA-SR _t (n)	IDA-SR _{t+ID} (o)	IDA-SR _{t+ID} (n)
Food	HR@10	0.1097	0.1028	0.1309	0.1132
	NDCG@10	0.0730	0.0661	0.0943	0.0716
Instruments	HR@10	0.1250	0.1165	0.1304	0.1174
	NDCG@10	0.0821	0.0680	0.0872	0.0696
Arts	HR@10	0.1130	0.1039	0.1304	0.1058
	NDCG@10	0.0708	0.0605	0.0828	0.0614

内容进行说明，其报告结果如下：

在表 2 中， $IDA-SR_t(o)$ 和 $IDA-SR_{t+ID}(o)$ 分别是原始论文报告的结果，前者是与物品 ID 无关的微调，后者是与物品 ID 相关的微调。 $IDA-SR_t(n)$ 和 $IDA-SR_{t+ID}(n)$ 是本报告复现的模型效果，前者是与物品 ID 无关的微调，后者是与物品 ID 相关的微调。

观察表 2 可知，在原论文报告的结果中，与物品 ID 相关的微调性能普遍优于与物品 ID 无关的微调，即模型性能的提高依赖于物品 ID 的微调。而本报告复现的模型中也呈现出了相同的变化趋势。可以观察到， $IDA-SR_{t+ID}(\text{复})$ 的性能也普遍优于 $IDA-SR_t(\text{复})$ 的效果。加入物品 ID 的微调能够使得模型更加有效地捕捉物品之间的共现关系。

在全部数据集上，本论文复现的结果已经非常接近原论文的结果。在与物品 ID 无关的微调设置下，本报告复现的结果距离原论文结果约有 1% 的差距；在与物品 ID 有关的微调设置下，本报告复现的结果距离原论文报告结果约有 2% 的差距。由此回答研究问题 1，本报告复现的模型性能已经接近原论文报告的结果，这证明了原论文报告的结果是可信的：基于物品文本表示的方法能够在微调的设置下达到良好的性能；同时该结果也证明了本报告的复现是有效的。

5.2 预训练任务有效性探究实验

本节主要回答研究问题 3。在 IDA-SR 模型中，提出了三种预训练任务，其中包括：下一物品预测任务 (next item prediction, 简称 np 任务)、掩码物品预测任务 (mask item prediction, 简称 mp 任务)、置换物品预测任务 (permuted item prediction, 简称 pp 任务)。为了探究这三种预训练任务是否有效辅助模型训练，我们引入了三种模型的变体。

IDA-SR wo np: 移除了下一物品预测任务的 IDA-SR 模型。

IDA-SR wo mp: 移除了掩码物品预测任务的 IDA-SR 模型。

IDA-SR wo pp: 移除了置换物品预测任务的 IDA-SR 模型。

我们依旧保留预训练-微调的范式，观察三种模型的变体和原始 IDA-SR 模型的性能。我们选择 Instrument 和 Arts 数据集进行实验，结果如图 3 所示：




图 3. 消融实验结果图

观察图 3 可知，在 Instruments 数据集上，移除 pp 任务反而使得模型性能上升至最好，保留全部的预训练任务性能反而不如移除 pp 任务的变体；在 Arts 数据集上，三个模型变体表现差别不大，保留全部任务的模型性能最优。

一种可能的解释是，Instrument 数据集历史交互充足，采用下一物品预测任务就足够学习到充分高质量的物品表示，但是引入置换物品预测任务反而会破坏和干扰物品之间共现关系的学习。np 任务和 mp 任务的性能表现相对稳定。

由此可以回答研究问题 2，即 IDA-SR 引入的三种预训练任务中，np 任务和 mp 任务基本可以适用于推荐场景并且性能表现稳定，但是 pp 任务作为一个数据增强策略，并不能够完全适用于推荐场景。pp 任务表现不稳定，在用户物品交互稀疏的场景中可以增强模型的能力，但是在用户物品交互充足的场景中可能会干扰物品表示的学习。

5.3 影响模型性能瓶颈的因素

本节主要回答研究问题 3。观察表 2 可以发现，本报告复现的模型性能并没有完全达到原论文报告的结果。因此，在本节中主要分析其原因和影响模型性能瓶颈的因素。本节主要是通过分析在模型结构中，各个模型层的占比进而分析影响模型性能的因素。以 Instruments 数据集为例子，分析在该数据集下，IDA-SR 模型各个层之间的参数占比，如表 3 所示。

表 3. 模型参数分布

模型层名称	参数量	占比	是否可学习
物品文本编码表示	7653888	82.77%	否
语义转换层	525056	5.68%	是
序列偏好编码层	1054208	11.40%	是
位置编码层	13056	0.14%	是
其他参数层	512	0.01%	是

观察表 3 可知，模型中不可学习的参数量占比高达约 83%，主要来自于预训练语言模型中提取的物品文本编码表示；而中间模型层的占比约 17%。

目前学术界和工业界对于推荐系统的一个基本共识是，目前的推荐算法不具备自然语言模型的伸缩法则 (Scaling Law) 特性，即模型效果不会随着模型参数规模的增大而持续上升。例如，IDA-SR 模型的参数量主要集中在物品编码表示 embedding 层，占比为 83%。在这种情况下，如果继续增加物品的 embedding size 能够获得的效果收益其实是有限的，它并不会随着 embedding size 的增加而单调上升。因为推荐模型是过参数化的，在过参数化的情况下，进一步增大模型的参数规模对效果的影响是有限的。与此同时，增加中间的序列偏好编码层和语义转换层的深度和宽度可以在一定程度上带来模型性能的提高，但不是决定模型性能瓶颈最重要的因素。

因此可以得出结论，IDA-SR 模型的性能瓶颈主要来源于两个因素：(1) 底层的物品表示，即物品表示 embedding 层，由于在 IDA-SR 模型中，主要采用物品文本 embedding 作为物品表示，因此预训练的物品文本表示的质量决定了模型的性能上限。(2) 语义转换层的性能，即预训练的文本语义是否能够有效转换并适应推荐空间。因为预训练语言模型的底层文本表示是在大规模语料库上通过自监督或者无监督的方式进行训练，并没有有效适配推荐领域，因此无法直接适用于推荐空间。如果语义转换层性能较弱，则无法有效利用预训练的文本表示。

对于第一个影响因素，采用模型参数更大、性能更优越的语言模型提取的文本表示应该可以增强性能，或者针对推荐领域进行微调。但是预训练语言模型的预训练和微调成本较高，并且受限于高校实验室的资源有限，因此本报告采用了业界开源且常见的 BERT 模型进行预训练文本语义提取；对于第二个因素，考虑到 IDA-SR 模型的语义转换层仅仅采用了两层的 MLP 实现，网络深度浅，可能无法有效利用文本表示的能力，因此，本文提出了一种基于局部敏感哈希的语义转换组件网络来增强文本语义的转换能力，这也是该创新点提出的动机。

5.4 基于局部敏感哈希的语义映射网络有效性

本节的设置主要是为了回答研究问题 4 和研究问题 5。首先，下表给出了引入了语义映射网络的模型变体和原有复现的 IDA-SR 模型的性能比较。

表 4. 性能比较

data	Metric	IDA-SR _t (n)	IDA-SR _{t+ID} (n)	LSH-SR
Food	HR@10	0.1028	0.1132	0.1193
	NDCG@10	0.0661	0.0716	0.0816
Instruments	HR@10	0.1165	0.1174	0.1175
	NDCG@10	0.0680	0.0696	0.0656
Arts	HR@10	0.1039	0.1058	0.1137
	NDCG@10	0.0605	0.0614	0.0637

观察表 4，在 Arts 和 Food 数据集上，本报告改进的 LSH-SR 模型性能远远超过 IDA-SR_{t+ID}(n) 模型，在 Food 数据集上，{Hit@10, NDCG@10}增幅分别为{5.38%, 13.97%}。在 Arts 数据集上，{Hit@10, NDCG@10}增幅分别为{7.47%, 3.75%}。在 Instruments 数据集上，本报告改进的 LSH-SR 模型性能未能有效地发挥效果，但是其性能与 IDA-SR_t(n) 模型相当。由此可以回答研究问题 4，即本文提出的基于局部敏感哈希的语义映射网络是有效

提高文本表示迁移至推荐领域的能力。

为了探究在 $LSH-SR$ 模型中参数的影响,本报告进行了对应的消融实验。在 instruments 数据集上进行消融实验, 评估指标为 NDCG@10。其消融实验结果如表 5 所示:

表 5. LSH 模型消融实验结果

消融模型层	NDCG@10
DNN layer=1	0.0728
DNN layer=2	0.0709
DNN layer=3	0.0697
DNN layer=4	0.0730
hash emb num=1	0.0656
hash emb num=2	0.0688
hash emb num=3	0.0696
remove resnet gating	0.0645

观察表格数据可知, 增加 DNN 的层数使得 LSH-SR 的性能先下降后上升, 当 DNN layer 的层数为 4 的时候, 模型表现最优。增加哈希嵌入表的数量会使得模型性能提高, 说明该方法设计具有一定的可扩展性, 当哈希嵌入规模增大的时候, 能够更加有效地捕捉文本语义。移除残差连接的门控网络会导致模型性能大幅度下降, 这说明残差连接的门控网络是影响性能的关键因素。同时, DNN 的层数和哈希嵌入表数量也是一组重要的参数。

6 总结与展望

本报告复现了一种与物品 ID 无关的用户行为预训练的序列推荐方法-IDA-SR 模型。本报告根据其论文细节复现模型, 其复现结果在三个公开数据集接近原始论文报告的结果, 并且得到了和原论文报告中一致的结论: 基于物品文本表示的方法能够在部分场景上达到和基于物品 ID 的方法相似的性能, 但在下游任务上的性能提高依赖于基于物品 ID 微调。

同时, 本报告进行了充分的消融实验, 验证了 IDA-SR 模型提出的三个预训练任务的有效性, 证明 IDA-SR 模型中提出的置换物品预测任务表现不稳定, 在用户物品交互稠密的热场景中可能会干扰物品表示的学习; 报告还研究了影响模型性能瓶颈的原因, 发现底层的物品文本编码表示和语义空间适配层是两个最重要的影响因素。因此, 本文提出了一种基于局部敏感哈希的语义映射组件网络。该网络可以弥补预训练模型空间和推荐空间的语义差距, 有效地提高基于文本的语义表示迁移至推荐场景的能力。

在后续的研究中, 可以考虑在两个方向上进一步改进模型: (1) 采用规模更大、更适合推荐任务架构的预训练语言模型提取文本表示, 可以考虑端到端预训练、微调等方式提高文本表示的质量; (2) 引入更加有效的语义转换网络, 并和基于物品 ID 的建模方式结合, 有效地提高物品文本表示迁移辅助推荐算法的能力。

参考文献

- [1] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. Session-based recommendations with recurrent neural networks. *arXiv: Learning, arXiv: Learning*, Nov 2015.
- [2] Wang-Cheng Kang and Julian McAuley. Self-attentive sequential recommendation. In *2018 IEEE International Conference on Data Mining (ICDM)*, pages 197–206, 2018.
- [3] Shanlei Mu, Yupeng Hou, Wayne Xin Zhao, Yaliang Li, and Bolin Ding. Id-agnostic user behavior pre-training for sequential recommendation. In *Information Retrieval: 28th China Conference, CCIR 2022, Chongqing, China, September 16 – 18, 2022, Revised Selected Papers*, page 16 – 27, Berlin, Heidelberg, 2023. Springer-Verlag.
- [4] Tingting Zhang, Pengpeng Zhao, Yanchi Liu, Victor S. Sheng, Jiajie Xu, Deqing Wang, Guanfeng Liu, and Xiaofang Zhou. Feature-level deeper self-attention network for sequential recommendation. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence*, Aug 2019.
- [5] Yupeng Hou, Binbin Hu, Zhiqiang Zhang, and Wayne Xin Zhao. Core: Simple and effective session-based recommendation within consistent representation space. In *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR ’22, page 1796 – 1801, New York, NY, USA, 2022. Association for Computing Machinery.
- [6] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*, CIKM ’19, page 1441 – 1450, New York, NY, USA, 2019. Association for Computing Machinery.
- [7] Kun Zhou, Hui Yu, Wayne Xin Zhao, and Ji-Rong Wen. Filter-enhanced mlp is all you need for sequential recommendation. In *Proceedings of the ACM Web Conference 2022*, WWW ’22, page 2388 – 2399, New York, NY, USA, 2022. Association for Computing Machinery.
- [8] Shu Wu, Yuyuan Tang, Yanqiao Zhu, Liang Wang, Xing Xie, and Tieniu Tan. Session-based recommendation with graph neural networks. In *Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence and Thirty-First Innovative Applications of Artificial Intelligence Conference and Ninth AAAI Symposium on Educational Advances in Artificial Intelligence*, AAAI’19/IAAI’19/EAAI’19. AAAI Press, 2019.
- [9] Jianxin Chang, Chen Gao, Yu Zheng, Yiqun Hui, Yanan Niu, Yang Song, Depeng Jin, and Yong Li. Sequential recommendation with graph neural networks. In *Proceedings of*

- the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '21, page 378 – 387, New York, NY, USA, 2021. Association for Computing Machinery.
- [10] Kun Zhou, Hui Wang, Wayne Xin Zhao, Yutao Zhu, Sirui Wang, Fuzheng Zhang, Zhongyuan Wang, and Ji-Rong Wen. S3-rec: Self-supervised learning for sequential recommendation with mutual information maximization. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*, CIKM '20, page 1893 – 1902, New York, NY, USA, 2020. Association for Computing Machinery.
 - [11] Xu Xie, Fei Sun, Zhaoyang Liu, Shiwen Wu, Jinyang Gao, Jiandong Zhang, Bolin Ding, and Bin Cui. Contrastive learning for sequential recommendation. In *2022 IEEE 38th International Conference on Data Engineering (ICDE)*, May 2022.
 - [12] Chao Huang, Xiang Wang, Xiangnan He, and Dawei Yin. Self-supervised learning for recommender system. In *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '22, page 3440 – 3443, New York, NY, USA, 2022. Association for Computing Machinery.
 - [13] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North*, Jan 2019.
 - [14] Yupeng Hou, Shanlei Mu, Wayne Xin Zhao, Yaliang Li, Bolin Ding, and Ji-Rong Wen. Towards universal sequence representation learning for recommender systems. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, page 585 – 593, New York, NY, USA, 2022. Association for Computing Machinery.
 - [15] Yupeng Hou, Zhankui He, Julian McAuley, and Wayne Xin Zhao. Learning vector-quantized item representation for transferable sequential recommenders. In *Proceedings of the ACM Web Conference 2023*, WWW '23, page 1162 – 1171, New York, NY, USA, 2023. Association for Computing Machinery.
 - [16] Zheng Yuan, Fajie Yuan, Yu Song, Youhua Li, Junchen Fu, Fei Yang, Yunzhu Pan, and Yongxin Ni. Where to go next for recommender systems? id- vs. modality-based recommender models revisited. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '23, page 2639 – 2649, New York, NY, USA, 2023. Association for Computing Machinery.
 - [17] Wayne Xin Zhao, Shanlei Mu, Yupeng Hou, Zihan Lin, Yushuo Chen, Xingyu Pan, Kaiyuan Li, Yujie Lu, Hui Wang, Changxin Tian, Yingqian Min, Zhichao Feng, Xinyan Fan, Xu Chen, Pengfei Wang, Wendi Ji, Yaliang Li, Xiaoling Wang, and Ji-Rong Wen. Recbole: Towards a unified, comprehensive and efficient framework for recommendation algorithms. In *Proceedings of the 30th ACM International Conference on Information*

E& Knowledge Management, CIKM '21, page 4653 – 4664, New York, NY, USA, 2021. Association for Computing Machinery.

- [18] Jianmo Ni, Jiacheng Li, and Julian McAuley. Justifying recommendations using distantly-labeled reviews and fine-grained aspects. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, Jan 2019.